

Tecnológico de Monterrey

Actividad 5. Evaluación

Andre Guillermo Carvajal Flores

A01738830

Octubre 19, 2026

Analítica de datos y herramientas de inteligencia artificial

(Gpo 601)

1. Introducción y Contexto de Negocio

En el presente trabajo analizamos la información transaccional de ventas del socio formador **CLV**, empresa especializada en la distribución de productos dentales, insumos clínicos y equipo médico.

1. Preprocesamiento y Diagnóstico de Calidad: Tratamiento de nulos, estandarización de nombres de columnas, depuración fundamentada de registros no comerciales (precio zsh) y evaluación de valores atípicos (outliers) mediante el rango intercuartílico (IQR).
2. Regresión Lineal (Simple y Múltiple): Identificación del par de variables con mayor correlación en toda la empresa (precio unitario vs total facturado) y la incorporación del volumen de piezas para explicar de forma realista las operaciones de mayoreo, comparando de forma directa coeficientes y métricas de error.
3. Regresión Logística con Dicotomización: Transformación del comportamiento de compra en una variable binaria (menudeo vs mayoreo) y contraste empírico de las técnicas de reponderación de clases y sobremuestreo (Oversampling) para seleccionar el modelo óptimo de predicción comercial.

2. Preprocesamiento: Calidad de Datos, Nulos y Outliers

Comenzamos cargando la hoja *Histórico_Ventas* (21,632 filas × 14 columnas). Durante la inspección inicial, detectamos espacios en blanco accidentales en el encabezado de la columna *estado* ('estado '), los cuales limpiamos inmediatamente con la función *strip()* para garantizar la consistencia en el código.

En cuanto a valores faltantes, se verificó que la única variable con nulos fue el código postal (*cp*), con 492 registros que equivalen únicamente al **2.27%** del total. Las variables predictoras y objetivo (precio, unidades y facturación) se encontraron al 100% completas, por lo que no fue necesario aplicar imputaciones artificiales.

Depuración Comercial: Filtrado de Registros en Cero

Se identificaron 1,612 observaciones correspondientes a transacciones con importe o tarifa nula. Un análisis de la dinámica comercial de CLV reveló que estas operaciones no representan inconsistencias en la recolección, sino distribuciones de demostración para especialistas, reposiciones por garantía o bonificaciones sin costo. Su inclusión habría sesgado los promedios globales y distorsionado la tendencia operativa; en consecuencia, se procedió a su depuración, conservando un conjunto final de 20,020 registros comerciales para la construcción de los modelos.

Diagnóstico de Outliers mediante Rango Intercuartílico (IQR)

Aplicamos el criterio estándar del Rango Intercuartílico (*IQR = Q3 - Q1*) calculando los límites [Q1 - 1.5·IQR, Q3 + 1.5·IQR] sobre las tres variables cuantitativas principales:

Variable	Q1 (25%)	Mediana	Q3 (75%)	Límite Sup. IQR	Outliers (Filas)	Outliers (%)
precio_unitario	.00	.52	,440.00	,300.00	1,076	5.37%
total_unidades	1.00	1.00	2.00	3.50	2,423	12.10%
total_neto	.48	,068.97	,460.00	,798.28	2,150	10.74%

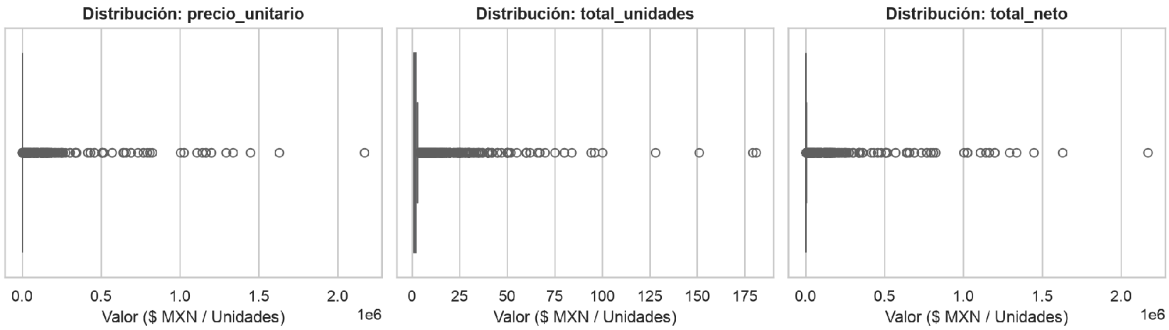


Figura 1: Diagramas de caja (Boxplots) horizontales para las variables cuantitativas clave.

Justificación de Outliers: Como se aprecia en la Figura 1, existe un sesgo natural hacia la derecha. La decisión técnica fue **c**onservar estas observaciones debido a que reflejan compras reales y legítimas de productos de alta gama (motores de implantes, hornos de cerámica dental y paquetes de fresas), los cuales forman parte esencial de la facturación de la empresa.

3. Regresión Lineal Simple: Correlación Máxima y Modelo

Calculamos la matriz de correlación de Pearson entre las variables cuantitativas para identificar la relación matemática más fuerte del negocio.

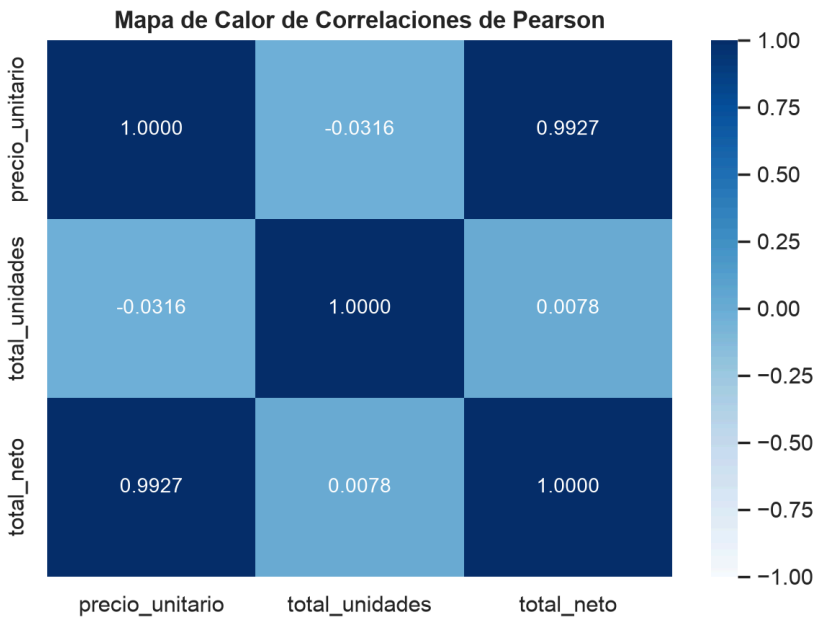


Figura 2: Mapa de calor de correlaciones de Pearson entre variables cuantitativas.

La correlación más alta de toda la base corresponde a **precio_unitario vs total_neto**, alcanzando un valor de **r = 0.9927**. Con este sustento, formulamos el modelo de Regresión Lineal Simple particionando los datos en 80% entrenamiento y 20% prueba:

$$\textbf{total_neto} = 1130.38 + (0.9996 \cdot \textbf{precio_unitario})$$

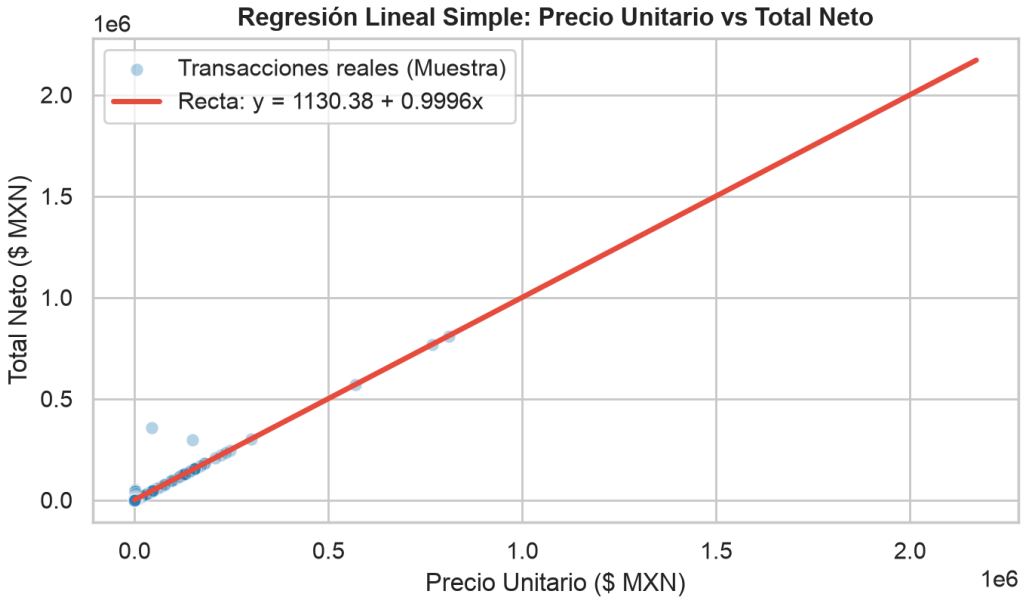


Figura 3: Dispersión y recta ajustada de Mínimos Cuadrados Ordinarios (OLS).

Interpretación Estadística y Comercial:
• **Coeficiente R^2 = 0.9698 (96.98%):** El precio del producto explica casi la totalidad de la variación en el total facturado.
• **Pendiente (β1 = 0.9996):** Por cada peso que se incrementa el precio unitario, el total neto se eleva en zsh.9996 MXN.
• **Limitación del Modelo Simple:** A pesar del excelente ajuste, el Error Absoluto Medio es alto (**MAE = ,607.17 MXN**). Esto ocurre porque el modelo simple asume que cada transacción es de una sola unidad, sesgando fuertemente el intercepto base a ,130.38 MXN.

4. Regresión Lineal Múltiple y Comparación de Modelos

Para corregir el sesgo de omisión del modelo simple, incorporamos la variable *total_unidades* como segundo predictor cuantitativo determinante. El modelo múltiple ajustado se formuló como:

total_neto = 198.59 + (1.0008 · precio_unitario) + (323.68 · total_unidades)

Métrica / Coeficiente	Modelo Lineal Simple	Modelo Lineal Múltiple
Intercepto (β0)	,130.3805	.5864
Coeficiente: precio_unitario (β1)	0.9996	1.0008
Coeficiente: total_unidades (β2)	No incluido	323.6794
Bondad de Ajuste (R^2)	0.9698 (96.98%)	0.9722 (97.22%)
Error Absoluto Medio (MAE)	,607.17 MXN	,263.69 MXN
Raíz del Error Cuadrático (RMSE)	,272.69 MXN	,011.51 MXN

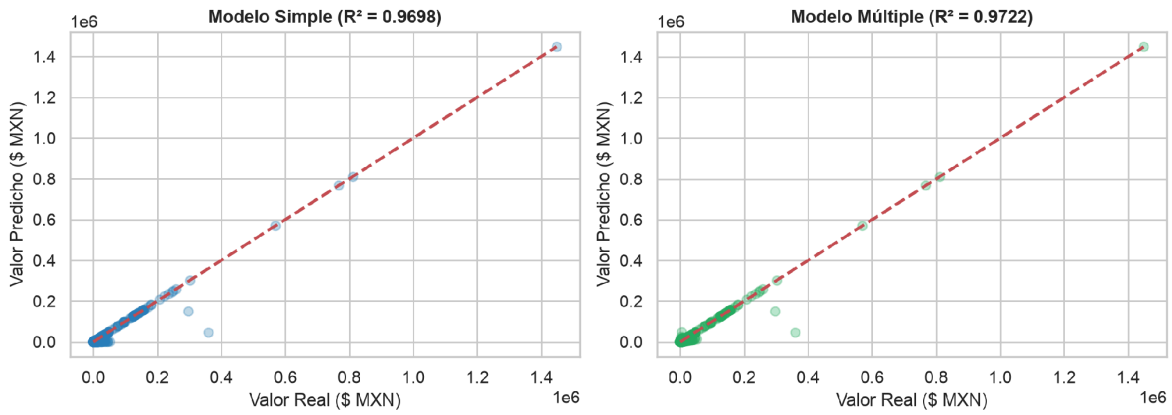


Figura 4: Comparación de Valores Reales vs Predichos para el Modelo Simple y Múltiple.

Justificación Comparativa de Coeficientes:
1. El coeficiente de volumen **β2 = 323.68** refleja que, manteniendo constante el precio del artículo, cada pieza adicional adquirida añade en promedio .68 MXN a la factura.
2. El intercepto disminuye dramáticamente de ,130.38 a **.59 MXN**, acercándose al valor teórico esperado.
3. En términos de precisión, el modelo múltiple reduce el MAE de ,607.17 a **,263.69 MXN**, lo que representa una **reducción de error del 21.4%**, demostrando una capacidad significativamente superior para predecir transacciones de mayoreo.

5. Regresión Logística: Dicotomización y Balanceo de Clases

Para dar cumplimiento al **Punto 7** del reto, convertimos el volumen transaccional en una variable dicotómica de segmentación comercial:
• **Clase 0 (Compra Unitaria / Menudeo):** Pedidos de exactamente 1 artículo (11,861 órdenes, **59.25%**).
• **Clase 1 (Compra por Volumen / Mayoreo):** Pedidos de más de 1 artículo (8,159 órdenes, **40.75%**).

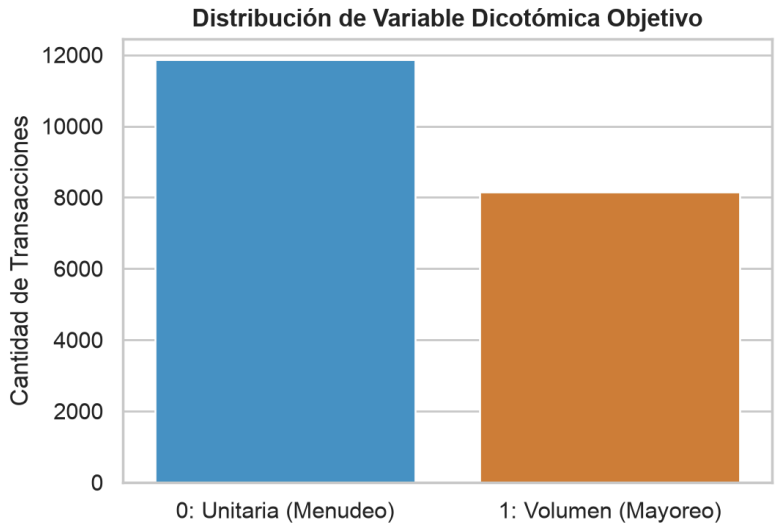


Figura 5: Distribución de la variable dicotómica objetivo en la base depurada.

Comparación de Estrategias y Selección del Modelo Definitivo

Utilizando como predictoras el logaritmo del precio (*log_precio*) y la marca líder (*es_marca_vita*), evaluamos los tres enfoques sobre un conjunto de prueba del 25% (5,005 observaciones):

Estrategia de Modelado	Accuracy	Precision (Clase 1)	Recall (Sensibilidad)	F1-Score	ROC-AUC
Modelo Base (Sin balancear)	62.44%	61.87%	20.44%	0.3073	0.6911
Reponderación (class_weight="balanced")	65.09%	56.01%	66.96%	0.6100	0.6911
Modelo Final: Oversampling	65.75%	56.55%	69.02%	0.6216	0.6997

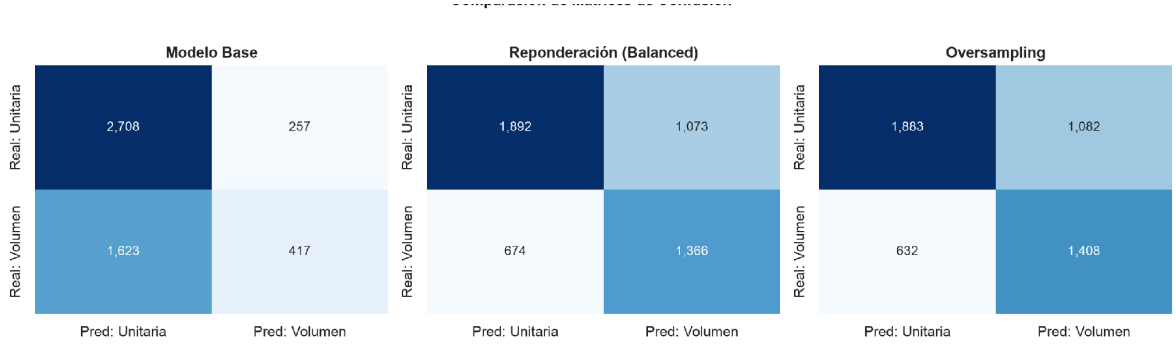


Figura 6: Matrices de Confusión comparativas en el conjunto de prueba (5,005 órdenes).

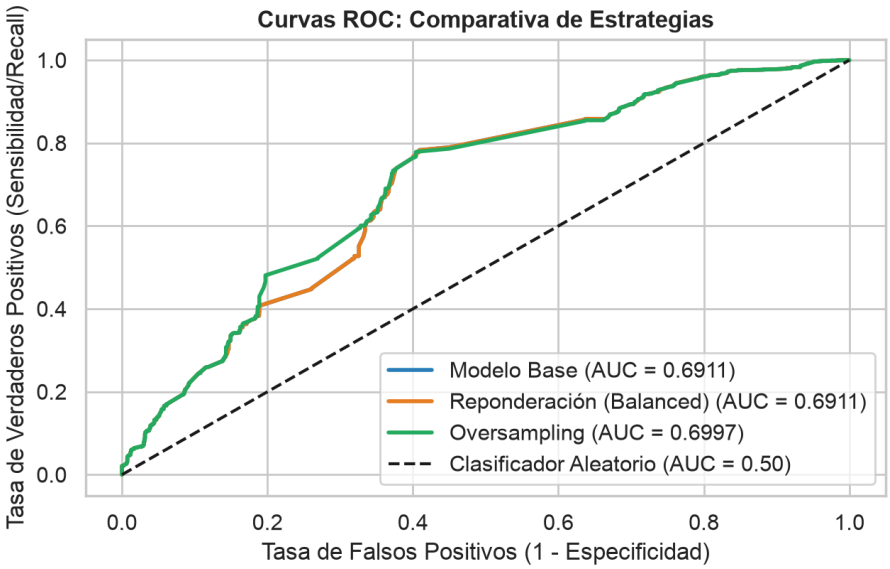


Figura 7: Curvas Características Operativas del Receptor (ROC) y valores AUC.

Justificación de la Selección del Modelo Final:

• **El Error del Modelo Base:** Aunque reporta un Accuracy del 62.44%, su Recall de **20.44%** es inviable para el negocio, ya que deja escapar a 8 de cada 10 compradores mayoristas al clasificarlos erróneamente como compras unitarias.

• **Superioridad del Oversampling:** El modelo entrenado con **Oversampling** alcanza el mayor Recall de toda la prueba (**69.02%**), superando a la Reponderación (66.96%), duplicando el F1-Score (de 0.307 a **0.6216**) y maximizando el área bajo la curva a **AUC = 0.6997**. Por esta razón, se selecciona formalmente como la solución final para CLV.